



RNCP35288 CDS

# Walmart sales

## Supervised Machine Learning

**Rédacteur :** Jean-Yves Vuillequez





# Contexte




**Objectif :** prédire Weekly\_Sales (par magasin / semaine) pour mieux planifier les stocks et opérations.



**Données à disposition :** ventes + variables « externes » (température, fuel price, CPI, chômage) + Holiday\_Flag + date




**Approche :**






# EDA

Weekly\_Sales total (somme) au fil du temps



Saisonnalité : Weekly\_Sales par mois



Top 10 Stores par Weekly\_Sales moyenne



- **Ventes dans le temps** : présence de pics (événements / holidays) et une forte dynamique temporelle
- **Saisonnalité par mois** : certaines périodes (ex : fin d'année) ont des ventes structurellement plus hautes.
- **Ventes moyennes par Store (Top 10)** : hétérogénéité très forte entre magasins et un effet « Store » ultra dominant dans le modèle.



# Métriques et protocole

## Critères d'évaluation du modèle de régression



### Métriques choisies :

- **RMSE** - « Combien je me trompe, en unités métier ? » : Mesure l'erreur moyenne **en unités de vente** (target : Weekly\_Sales)
- **R<sup>2</sup>** - « Quelle part de la variabilité le modèle explique ? » : Mesure la **qualité d'explication du modèle**



### Pourquoi ces métriques :

- **RMSE** : pénalise les grosses erreurs → important car les **pics de vente** coûtent cher si mal anticipés.
- **R<sup>2</sup>** : permet de dire si le modèle capte le signal au-delà d'une simple moyenne.



# Agrégation des résultats

Baseline vs Ridge/Lasso : amélioration de la généralisation

**Pipeline** : imputer + scaler + one-hot + modèle

| Modèle       | Alpha (si applicable) | RMSE train    | RMSE test      | R <sup>2</sup> train | R <sup>2</sup> test | Diagnostic                      |
|--------------|-----------------------|---------------|----------------|----------------------|---------------------|---------------------------------|
| Baseline     | -                     | 66,360        | 182,176        | 0.990                | 0.900               | Overfitting                     |
| <b>Ridge</b> | <b>0.00546</b>        | <b>70,891</b> | <b>150,862</b> | <b>0.989</b>         | <b>0.931</b>        | <b>Meilleure généralisation</b> |
| Lasso        | 48.329                | 69,878        | 152,926        | 0.989                | 0.929               | Bonne généralisation            |

**Avec optimisation** : Pipeline + optimisation date et holiday


| Modèle | Alpha (si applicable) | RMSE train | RMSE test | R <sup>2</sup> train | R <sup>2</sup> test | Diagnostic                      |
|--------|-----------------------|------------|-----------|----------------------|---------------------|---------------------------------|
| Ridge  | 0.06951               | 79,496     | 138,791   | 0.985                | 0.953               | <b>Meilleure généralisation</b> |




# Résultats et optimisations 1/2

## Focus Ridge

Ridge (test) :  $y_{\text{true}}$  vs  $y_{\text{pred}}$



Ridge : Top 20 coefficients (valeur absolue)



- **Qualité de prédiction (test)** : les points sont globalement proches de la diagonale. Ridge généralise correctement et capture le niveau de ventes sur des semaines “standard”.
- **Concentration des erreurs** : l'écart augmente sur les valeurs extrêmes ou des pics de ventes
- **Principaux coefficients** : les effets Store dominant et ensuite des variables temporelles (Week/Quarter/Month). Cohérent avec la saisonnalité et l'hétérogénéité magasins



# Résultats et optimisations 2/2

## Interprétation des résultats



- **Baseline** : L'écart entre train et test est très prononcé (RMSE 66k / 182k). Il y'a un surapprentissage et une généralisation faible.
- **Ridge / Lasso** : Le RMSE test est en baisse (151 pour Ridge et 153k pour Lasso) et le  $R^2$  test sur Ridge est positionné à 0.93. Le modèle est plus stable et gagne en robustesse sur des données non vues.
- **Avec optimisation des features date + "holiday"** : Ridge descend à 139k de RMSE test et monte à 0.95 de  $R^2$ . Il s'agit du meilleur compromis performance/stabilité avec une amélioration de la prédiction.



Jedha

Merci pour votre attention  
Des questions ?

